

Análise comparativa entre aprendizado profundo e radiômica para classificação de nódulos mamários no dataset CBIS-DDSM

Bernardo Nunes Paixão
Universidade Federal do Paraná
(UFPR)
Curitiba, Paraná, BR

Henrique Villela Silva
Universidade Federal do Paraná
(UFPR)
Curitiba, Paraná, BR

Marcus Sebastião Adriano
Rocha Neto
Universidade Federal do Paraná
(UFPR)
Curitiba, Paraná, BR

Resumo

O câncer de mama apresenta desafios significativos para o diagnóstico auxiliado por computador, especialmente devido à natureza ruidosa das mamografias. Este estudo compara o poder preditivo de características extraídas por Redes Neurais Convolucionais (ResNet50) e pela Radiômica clássica na classificação de lesões utilizando a base CBIS-DDSM. Propõe-se um pipeline morfológico avançado de segmentação automática (integrando filtragem Bilateral, CLAHE, Otsu e contornos ativos Chan-Vese) em oposição à demarcação manual médica. Os resultados evidenciam que a fusão das características da ResNet50 com a radiômica de Otsu, acoplada ao SVM, obteve o desempenho máximo (F1-Score: 66.05%; Acurácia: 67.74%). Notavelmente, a extração baseada na segmentação automática superou a demarcação manual médica com o classificador Random Forest (65.10% contra 60.41% de acurácia). Conclui-se que a fusão de características profundas com pipelines morfológicos robustos mitiga a necessidade de exaustivas anotações manuais de lesões, consolidando-se como uma arquitetura otimizada para Sistemas de Suporte à Decisão Clínica (CDSS) na triagem mamográfica.

Keywords

Câncer de Mama, CBIS-DDSM, ResNet50, Radiômica, Segmentação Automática, Chan-Vese, Otsu.

ACM Reference Format:

Bernardo Nunes Paixão, Henrique Villela Silva, and Marcus Sebastião Adriano Rocha Neto. 2026. Análise comparativa entre aprendizado profundo e radiômica para classificação de nódulos mamários no dataset CBIS-DDSM. In . ACM, New York, NY, USA, 4 pages. <https://doi.org/10.1145/1122445.1122456>

1 Introdução

Segundo a Organização Mundial da Saúde (OMS), o câncer de mama é a neoplasia maligna mais incidente e uma das principais causas de mortalidade entre a população feminina a nível global. No Brasil, dados do Instituto Nacional de Câncer (INCA) reiteram este cenário, destacando a urgência de intervenções eficazes. Neste contexto, a detecção precoce por meio de mamografias de raios-X é fundamental para a redução da mortalidade associada à doença. Sistemas de

Diagnóstico Auxiliado por Computador (CAD) desempenham um papel crítico ao prover uma análise objetiva de estruturas biomédicas complexas aos radiologistas, especialmente no panorama da oncologia de precisão [5].

A segmentação manual e a caracterização de nódulos constituem tarefas onerosas e sujeitas à variabilidade interobservador [7]. Para investigar a viabilidade da automação clínica, este artigo apresenta um estudo comparativo cujas contribuições fundamentam-se em três eixos: (1) o delineamento de um algoritmo autônomo de segmentação por contornos ativos em face da demarcação médica; (2) a avaliação híbrida entre o aprendizado profundo (ResNet50) e a Radiômica; e (3) a análise do impacto da redução de dimensionalidade (PCA) na captura de sutilezas texturais de nódulos mamários malignos.

2 Metodologia

2.1 Base de dados

A validação ocorreu sobre a base pública *Curated Breast Imaging Subset of DDSM* (CBIS-DDSM) [1]. As instâncias foram rigorosamente segregadas utilizando as divisões nativas de treinamento e teste para mitigar o risco de vazamento de dados (*data leakage*).

2.2 Segmentação das lesões via algoritmos de processamento

Para garantir uma extração radiômica isenta de intervenção manual e competitiva em relação às marcações dos radiologistas (*Ground Truth*), desenvolveu-se um pipeline morfológico estruturado em sete etapas:

- (1) **Pré-processamento:** Filtro Bilateral (mitigação de ruído preservando bordas), seguido de CLAHE (equalização local) e borramento Gaussiano suave.
- (2) **Binarização Adaptativa:** Limiarização por Otsu [6] para separação preliminar de intensidades.
- (3) **Limpeza Morfológica:** Abertura e Fechamento para eliminação de ruídos pontuais e estabilização da forma da massa [6].
- (4) **Isolamento de Componente:** Filtragem do maior componente conectado central, descartando artefatos periféricos.
- (5) **Preenchimento (Fill Holes):** Fechamento de lacunas internas para garantir a solidez anatômica do nódulo.
- (6) **Contornos Ativos (Chan-Vese):** Evolução de curvas para abraçar as espículas características de tumores malignos [3].
- (7) **Limite de Segurança:** Restrições geométricas contra vazamento para tecidos densos adjacentes.

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than ACM must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

Conference'17, Washington, DC, USA

© 2026 ACM.

ACM ISBN 978-x-xxxx-xxxx-x/YYYY/MM
<https://doi.org/10.1145/1122445.1122456>



Figura 1: Exemplo da segmentação proposta: Imagem bruta (esquerda), máscara refinada via Chan-Vese (centro) e sobreposição delimitando o nódulo (direita).

2.3 Extração e classificação

A extração numérica ocorreu por **Redes Neurais** (vetor de 2048 atributos da ResNet50 [2], cujas camadas densas finais foram removidas) e **Radiômica** (descritores de textura e forma via biblioteca *Pyradiomics* [4]).

Para testar a retenção informacional e os efeitos de *overfitting*, aplicou-se PCA (preservando 95% da variância) em cenários isolados e na fusão prematura (*Early Fusion*) de ambas as abordagens. As avaliações rigorosas na partição de teste ocorreram utilizando os classificadores Random Forest (100 árvores) e Support Vector Machine (SVM, kernel RBF).

3 Resultados e discussão

A avaliação metodológica gerou três descobertas empíricas sobre a detecção de anomalias em imagens de raios-X, detalhadas a seguir e consolidadas na Tabela 1.

3.1 Análise de segmentação

Para validar o pipeline morfológico proposto, mensurou-se a fidelidade geométrica das máscaras geradas por Otsu e contornos ativos (Chan-Vese) em relação às demarcações especialistas (Ground Truth). Utilizou-se o Coeficiente de Similaridade de Dice (*DSC*) e a Interseção sobre a União (*IoU*). Nos cenários de alta performance (e.g., UUIDs 84453085, 58503148 e 73201088), o método atingiu excelente convergência espacial ($DSC > 0.89$ e $IoU > 0.80$), impulsionado pelo alto contraste intrínseco dos nódulos. Em contrapartida, nos casos complexos (e.g., UUIDs 26643670, 48202206 e 22428056), o índice de Dice decaiu para intervalos entre 0.39 e 0.56 devido ao parênquima mamário denso, gerando vazamento marginal (falsos positivos) ou subsegmentação focal (falsos negativos).

Apesar dessas limitações em tecidos heterogêneos, a radiômica automática baseada no pipeline proposto (Otsu-Bruto) superou a demarcação manual médica na classificação final, registrando 62.22% contra 54.85% de F1-Score. Esse ganho ocorre porque o algoritmo captura gradientes sutis de textura matemática frequentemente desconsiderados na análise visual subjetiva. Além disso, a fusão das características dos atributos da ResNet50 com a radiômica automática alcançou o ápice experimental (67.74% de acurácia e 66.05% de F1-Score via SVM). O pipeline prova-se, portanto, computacionalmente eficiente e clinicamente viável para operação autônoma, mapeando com clareza os cenários críticos onde a introdução futura de modelos profundos de segmentação (e.g., U-Net) pode atuar de forma complementar.

3.2 Otsu supera a demarcação médica

A descoberta inicial mais notável recai sobre a qualidade topológica da segmentação proposta. Observou-se que o uso do Random Forest sobre as características da *Radiômica Otsu - Bruto* atingiu 65.10% de acurácia, suplantando 60.41% extraídos a partir da demarcação desenhada pelo radiologista (*Radiômica Médico - Bruto*). Isso prova cientificamente que o encadeamento morfológico validado pelo algoritmo de Chan-Vese conseguiu otimizar a captura biométrica das matrizes de textura do tumor, superando a própria análise clínica no tratamento do ruído periférico de fundo.

3.3 Combinação das características de extração

Embora a extração latente autônoma via rede convolucional (ResNet Pura com SVM) tenha alcançado expressivos 67.16% de acurácia, a união complementar das abstrações do *Deep Learning* com a textura matemática de baixo nível revelou-se a abordagem vitoriosa. O cenário fundido *Radiômica Otsu + ResNet - Bruto*, quando alimentado ao classificador SVM, registrou as métricas de excelência de todo o experimento: 67.74% de Acurácia global e um sólido 66.05% de F1-Score (Figura 3).

3.4 Comportamento dos classificadores

Uma análise crítica das métricas revela que a superioridade dos algoritmos alternou de acordo com a natureza dos atributos extraídos das mamografias. O classificador *Random Forest* apresentou melhor desempenho nos cenários puramente radiômicos (ex: 65.10% contra 61.58% do SVM no cenário *Otsu Bruto*). Em contrapartida, o SVM com kernel RBF dominou amplamente os cenários que envolviam a ResNet50 (atingindo o pico de 67.74% na fusão de características).

Essa inversão de desempenho é justificada pela geometria do espaço de características e pela natureza da imagem biomédica. Mamografias são exames de baixo contraste, onde a diferença entre tecido denso e nódulos malignos gera muito ruído nas extrações de textura clássica. O *Random Forest*, por ser um *ensemble* de árvores de decisão baseadas em partições ortogonais da entropia, realiza uma seleção implícita de *features*. Ele ignora descritores radiômicos ruidosos (como irregularidades de iluminação do Raio-X) e foca apenas nas regras morfológicas mais discriminativas (como a esfericidade ou entropia da GLCM), conferindo-lhe alta robustez.


Por outro lado, o SVM tenta otimizar uma margem de separação considerando todos os eixos simultaneamente, o que o torna vulnerável a características radiômicas irrelevantes. No entanto, ao processar os vetores latentes da ResNet50, o cenário inverte-se. A ResNet não extrai atributos interpretáveis por regras de corte simples, mas sim um espaço topológico denso e contínuo de 2048 dimensões representando padrões de ativação de pixels. O SVM equipado com o kernel RBF (*Radial Basis Function*) mapeia eficientemente esse espaço de alta dimensionalidade para encontrar hiperplanos de separação não-lineares, lidando com extrema precisão com as abstrações texturais das espículas tumorais, onde o *Random Forest* fragmenta-se em ramificações ineficientes.

3.5 O impacto da redução de dimensionalidade

Ao longo dos rigorosos testes executados, a aplicação da Análise de Componentes Principais (PCA) reduziu quase invariavelmente a capacidade preditiva dos algoritmos (Figura 2). Ao condensar os

Tabela 1: Resultados Consolidados dos Classificadores na Base de Teste

Modelo	Características (Abordagem de Extração)	Acurácia (%)	Sensibilidade (%)	Espec. (%)	F1-Score (%)
Random Forest	1. Radiômica Médico - Bruto	60.41	55.78	63.92	54.85
Random Forest	2. Radiômica Médico - c/ PCA	59.53	57.14	61.34	54.90
Random Forest	3. Radiômica Otsu - Bruto	65.10	66.67	63.92	62.22
Random Forest	4. Radiômica Otsu - c/ PCA	60.70	62.59	59.28	57.86
Random Forest	5. Radiômica Otsu + ResNet - Bruto	63.64	68.03	60.31	61.73
Random Forest	6. Radiômica Otsu + ResNet - c/ PCA	58.65	65.31	53.61	57.66
Random Forest	7. ResNet + Radiômica Médico - Bruto	64.22	68.03	61.34	62.11
Random Forest	8. ResNet + Radiômica Médico - c/ PCA	58.94	64.63	54.64	57.58
Random Forest	9. ResNet Pura	65.69	71.43	61.34	64.22
SVM (RBF)	1. Radiômica Médico - Bruto	60.12	58.50	61.34	55.84
SVM (RBF)	2. Radiômica Médico - c/ PCA	59.24	57.82	60.31	55.02
SVM (RBF)	3. Radiômica Otsu - Bruto	61.58	66.67	57.73	59.94
SVM (RBF)	4. Radiômica Otsu - c/ PCA	59.24	65.31	54.64	58.01
SVM (RBF)	5. Radiômica Otsu + ResNet - Bruto	67.74	72.79	63.92	66.05
SVM (RBF)	6. Radiômica Otsu + ResNet - c/ PCA	67.74	70.75	65.46	65.41
SVM (RBF)	7. ResNet + Radiômica Médico - Bruto	66.28	70.07	63.40	64.17
SVM (RBF)	8. ResNet + Radiômica Médico - c/ PCA	66.28	68.03	64.95	63.49
SVM (RBF)	9. ResNet Pura	67.16	70.75	64.43	65.00

**Figura 2: Comparativo de F1-Score evidenciando os impactos da PCA e das segmentações nas abordagens propostas.**

dados radiômicos descartando cerca de 5% da variância explicada, o modelo de PCA eliminou oscilações texturais consideradas ruído estatístico, mas que, no contexto mamográfico, abrigavam as discrepâncias vitais entre as espículas malignas e as margens de tecidos benignos. Isso indica que, para a caracterização de massas mamárias via radiômica, a preservação da dimensionalidade bruta é preferível à compressão de atributos.

4 Conclusão

Este estudo estabeleceu com sucesso que a arquitetura ideal para a classificação de nódulos mamários em mamografias densas reside na fusão de características extraídas por redes convolucionais profundas e por métodos da radiômica clássica, aliadas ao rigor do classificador SVM. Ademais, atestou-se a superioridade preditiva de segmentações automáticas, devidamente refinadas por contornos ativos (Chan-Vese), frente à anotação médica tradicional, abrindo precedentes estruturais robustos para a implementação de sistemas CAD integralmente autônomos em fluxos de trabalho da vida real.




Figura 3: Matrizes de Confusão contrastando o modelo híbrido (esquerda) e a extração profunda isolada (direita).




Figura 4: Comparativo visual da segmentação automática. Acima: Exemplo de alta convergência geométrica em tecidos claros ($DSC = 0.904$). Abaixo: Desafios morfológicos devido a parênquima mamário denso, gerando falsos positivos ($DSC = 0.568$).

Referências

[1] Clark, K. et al. (2013). *The Cancer Imaging Archive (TCIA): Maintaining and Operating a Public Information Repository*. Journal of Digital Imaging.

[2] He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep Residual Learning for Image Recognition*. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (pp. 770-778).

[3] Chan, T. F., & Vese, L. A. (2001). *Active contours without edges*. IEEE Transactions on Image Processing.

[4] Van Griethuysen, J. J. M. et al. (2017). *Computational Radiomics System to Decode the Radiographic Phenotype*. Cancer Research.

[5] Liu, Z., Wang, S., Dong, D., Wei, J., Fang, C., Zhou, X., ... & Tian, J. (2019). *The Applications of Radiomics in Precision Diagnosis and Treatment of Oncology: Opportunities and Challenges*. Theranostics, 9(5), 1303.

[6] Gonzalez, R. C., & Woods, R. E. (2018). *Digital Image Processing* (4th ed.). Pearson.

[7] Brar, K. K., Singh, S., & Kaur, R. (2025). *Image segmentation review: Theoretical background and practical applications*. Computer Science Review.